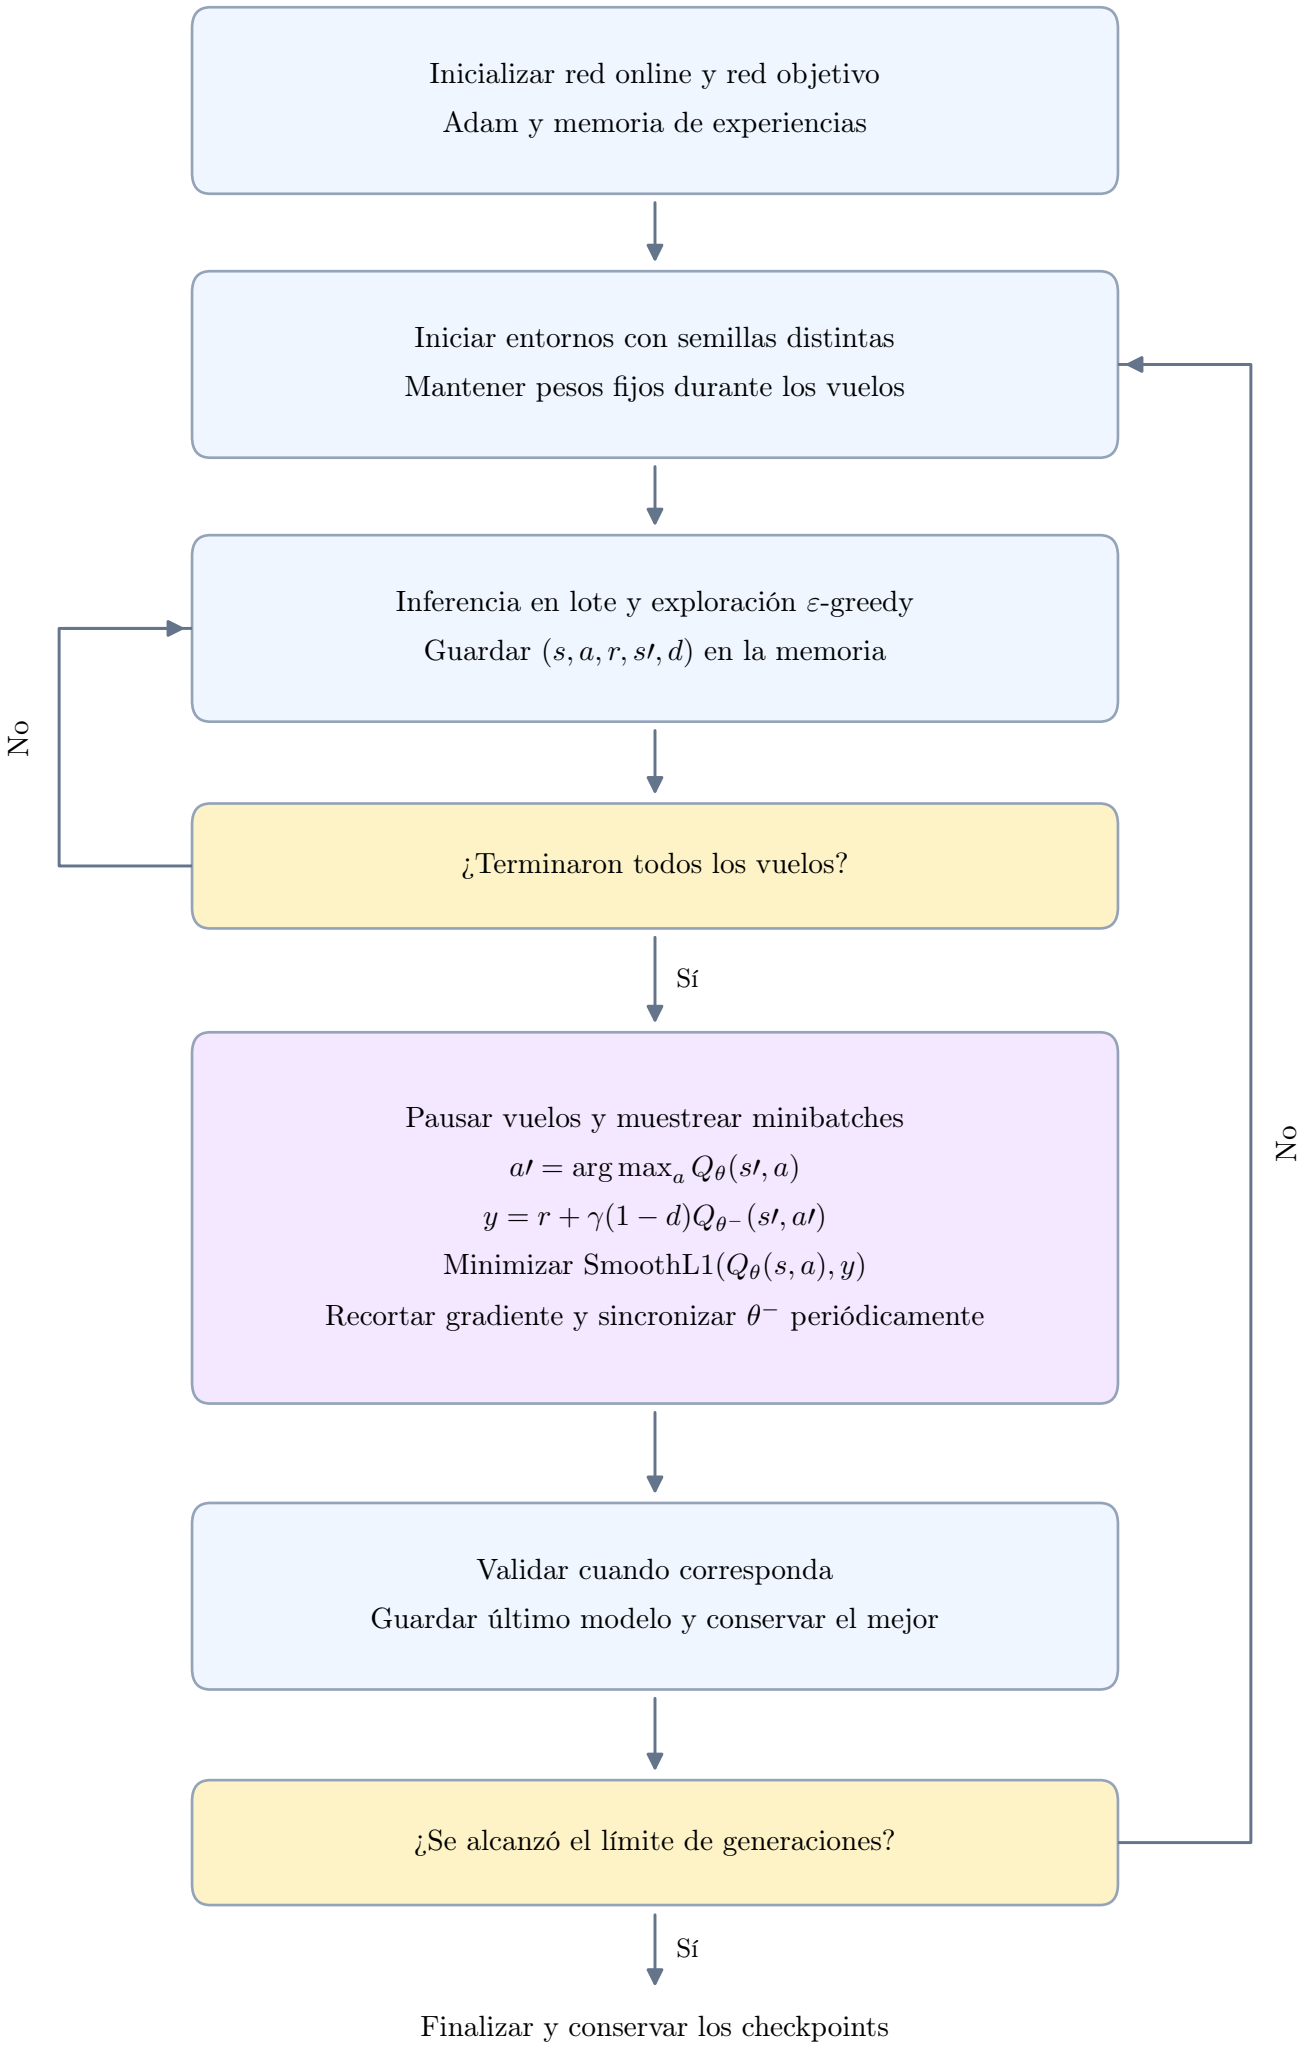

Entrenamiento por generaciones: Double DQN
Inicializar red online y red objetivo
Adam y memoria de experiencias
Iniciar entornos con semillas distintas
Mantener pesos fijos durante los vuelos
Inferencia en lote y exploración ε-greedy
Guardar $(s, a, r, s\prime, d)$ en la memoria
No
¿Terminaron todos los vuelos?
Sí
Pausar vuelos y muestrear minibatches
$a\prime = \arg\max_a Q_\theta(s\prime, a)$
$y = r + \gamma(1 - d)Q_{\theta^-}(s\prime, a\prime)$
Minimizar SmoothL1$(Q_\theta(s, a), y)$
Recortar gradiente y sincronizar θ^- periódicamente
Validar cuando corresponda
Guardar último modelo y conservar el mejor
¿Se alcanzó el límite de generaciones?
No
Sí
Finalizar y conservar los checkpoints